

Инвариантная самостоятельная работа

Задание 1.6

Задача: Подготовить тезисы доклада для выступления на предзащите выпускной квалификационной работы.

1. Актуальность

- Объём электронных учебных материалов (PDF, DOCX, конспекты, статьи) растёт быстрее, чем возможности их системного использования.
- Линейное чтение и полнотекстовый поиск отвечают на вопрос «где встречается слово», но не на вопрос «как связаны понятия и темы».
- Понятия, события и связи остаются внутри текста — нет прямой навигации по предметной области.
- Граф знаний + графовая СУБД — естественная модель «понятие — связь — понятие» с привязкой к источнику.
- Языковые модели дают инструмент автоматического извлечения структуры из неструктурированного текста.
- Вывод: актуальна прикладная система, объединяющая извлечение, хранение в графе и доступ пользователя к знаниям.

2. Объект, предмет, цель

Объект исследования

Методы работы с электронными учебными материалами как с неструктурированным источником знаний.

Предмет исследования

Методы и программные средства построения, хранения и извлечения графа знаний учебной предметной области с использованием графовой базы данных.

Цель

Разработать и теоретически обосновать прототип сервиса хранения и извлечения знаний из учебных материалов на основе графовой БД.

3. Задачи исследования

- Проблема + аналоги (поиск, LMS, RAG, KG)
- Методы извлечения: лингвистика, NER, LLM
- Модели знаний и графовые СУБД
- Требования, архитектура, стек
- Проектирование и реализация прототипа
- Тестирование, оценка, перспективы

4. Теоретическая и практическая значимость

Теоретическая

- Систематизация подходов к представлению учебных знаний в виде графа.
- Сопоставление методов извлечения сущностей и связей из текста.
- Обоснование применения графовых БД к задаче хранения и запросов к подграфу.

Практическая

- Работоспособный прототип: загрузка → извлечение → Neo4j → просмотр.
- Применение в учебном процессе (демонстрация инженерии знаний).
- Основа для развития: онтология, эталонная разметка, интеграция с поиском.

5. Методы и подход

- Конвейер: документ → текст (OCR при необходимости) → чанки → извлечение понятий и связей → граф.
- Двухпроходное извлечение: сначала понятия, затем связи с опорой на текст.
- Гибрид: LLM + NER (имена, места, организации) + постфильтрация и слияние сущностей.

- Хранение: узлы документ / фрагмент / понятие; связи упоминания и типизированные RELATED.

6. Программное решение (архитектура)

Назначение

- Сервис для загрузки учебных материалов, автоматического построения графа знаний и навигации по нему.

Компоненты

- Клиент: веб-интерфейс (Vue) — материалы, база знаний, граф.
- Сервер: API (FastAPI) — авторизация, документы, каталог, граф.
- Очередь: фоновая обработка (Redis, RQ).
- Извлечение: локальная LLM (Ollama), при необходимости NER (Natasha).
- Хранение графа: Neo4j (Cypher).
- Метаданные приложения: SQLite (пользователи, документы, чанки).

Пользовательские сценарии (что показать на демо)

- Вход → загрузка PDF.
- Просмотр чанков, знаний и графа по одному файлу.
- Общая база по нескольким материалам, фильтр документов.
- Граф: обзор и цепочка от выбранного понятия.

7. Инструменты и технологии

- Python, FastAPI · Vue 3
- Neo4j · Ollama · Natasha (NER)
- Redis / RQ · SQLite
- Tesseract (OCR для сканированных PDF)

8. Результаты работы

Главный результат

- Прототип сервиса хранения и извлечения знаний из учебных материалов на основе графовой БД.

Конкретно реализовано

- Загрузка и хранение документов (PDF, DOCX, TXT).
- Извлечение текста, фрагментация с перекрытием и границами абзацев.
- Автоматическое извлечение понятий и связей (LLM + NER + фильтры).
- Запись в Neo4j, слияние дубликатов сущностей.
- Каталог понятий и связей по пользователю и выбранным материалам.
- Визуализация: граф документа, обзорный граф, подграф «цепочка от понятия».
- Синхронизация графа с удалением документов в приложении.

По итогам тестирования (формулировки для устного доклада)

- На реальных учебных PDF система извлекает именованные понятия и связи между ними.

- Общая база объединяет материалы; фильтр по документам сужает предметную область.
- Цепочка от понятия позволяет локально исследовать тему (удобно для разбора текста).
- Качество связей зависит от модели и текста — нужна проверка по источнику; это ограничение, не «готовая экспертная система».

9. Перспективы развития

- Семантическое чанкование по структуре PDF (заголовки, параграфы).
- Эталонный корпус и метрики качества извлечения.
- RAG или поиск по графу + тексту.
- Расширение онтологии типов связей по предметным областям (история, математика).
- Роли преподавателя/студента, совместная разметка и правки графа.